« Maintenir la lisibilité du raisonnement des IA devient un nouvel enjeu dans le secteur »

CHRONIQUE

Alexandre Piquard
Journaliste au service Economie

Des acteurs de l'intelligence artificielle s'inquiètent du fait que les nouveaux modèles sont moins transparents sur les étapes menant à une réponse ou à une action, ce qui rendrait plus difficile leur surveillance, explique, dans sa chronique au « Monde », Alexandre Piquard.

Publié aujourd'hui à 17h00 | Lecture 2 min.

Offrir l'article
Lire plus tard

Article réservé aux abonnés

« Les modèles deviennent beaucoup plus intelligents, même sans aucun recours au raisonnement verbalisé. » Ce constat, dressé en septembre par Jakub Pachocki, le responsable scientifique d'OpenAI, résume l'un des dilemmes auxquels le secteur de l'intelligence artificielle (IA) fait face actuellement. En effet, explique-t-il dans un post de blog, depuis 2024 et la publication par la start-up du premier modèle d'IA dit « de raisonnement », l'architecture de la plupart des grands modèles de traitement du langage repose sur l'idée suivante : *« une grande part des capacités du modèle provient d'un processus de raisonnement verbalisé, le raisonnement détaillé, également appelé “chain of thought”* [chaîne de pensée]. *»*

Tout utilisateur ayant formulé une requête complexe à un assistant d'IA comme ChatGPT, Claude ou Gemini, a pu voir apparaître ces bouts de texte qui défilent pendant que le modèle semble *« réfléchir »* avant de donner sa réponse. Cela montre que celui-ci est poussé à s'interroger avant de délivrer sa réponse.

La surveillance du « raisonnement détaillé », lisible en langage naturel en anglais, est très utile, car elle est le principal moyen utilisé pour tenter de sécuriser les IA. En cas d'incident, elle est aussi précieuse : l'analyse de ces traces écrites a permis de reconstituer les actions des centaines d'agents d'OpenAI qui ont mené des cyberattaques contre la plateforme Hugging Face, en juillet, ouvrant un grand débat sur la sécurité des IA.

Or, pour M. Pachocki, ce moyen est désormais fragilisé. *« Nos évaluations indiquent que notre capacité à nous fier à la surveillance de la “chain of thought” diminue progressivement »*, écrit-il. Selon le média américain *The Information*, ce recul serait en partie lié à une nouvelle technique, utilisée par OpenAI et appelée « recurrent depth », qui conduit le modèle à traiter la même information un nombre variable de fois, mais sans passer par les étapes successives de « raisonnement » lisible. Dans un article paru en 2025, des chercheurs avaient déjà évoqué, parmi les risques pour la *« monitorabilité des IA »*, l'émergence de nouvelles architectures de modèle. Certains envisagent ainsi de permettre aux IA de raisonner dans des langages non humains, par exemple avec des chiffres.

Inquiétudes

Les traces de raisonnement verbalisé ne sont certes pas un moyen de surveillance parfait, car le volume énorme produit par les milliers d'agents IA rend difficile leur lecture par des humains et nécessite le recours à d'autres IA pour les analyser. De plus, les modèles peuvent parfois chercher à les modifier pour dissimuler une action – en laissant toutefois souvent de nouvelles traces.

Toutefois, leur perte potentielle suscite des inquiétudes. Le développement du *« raisonnement opaque »* évoqué par OpenAI pourrait être la *« pire évolution pour la sécurité de l'IA à ce jour »*, a estimé, sur le réseau social X, Ryan Greenblatt, du cabinet d'audit METR, qui a participé à l'analyse de l'incident survenu sur la plateforme Hugging Face. Maintenir la lisibilité du raisonnement des IA devient un nouvel enjeu dans le secteur.

Lire aussi | L'IA qui s'améliore elle-même, nouvel horizon controversé des grands laboratoires comme OpenAI et Anthropic

Pour apaiser les craintes qui s'expriment, OpenAI affirme vouloir préserver la *« monitorabilité »* des IA, avec de nouveaux moyens notamment, par exemple en surveillant les *« activations »* dans les réseaux de neurones du modèle d'IA lorsqu'il effectue telle ou telle action de raisonnement – un peu à la manière d'une image IRM pour un cerveau humain. Ce domaine, aux résultats encore incertains, est aussi exploré par Anthropic. Une autre piste évoquée par OpenAI est le recours aux *« confessions »*, à savoir demander à une IA de dire quelles actions ou quels raisonnements elle a menés.

Cependant, d'autres acteurs vont plus loin. *« La transparence du raisonnement verbalisé du modèle n'est pas négociable »*, a ainsi insisté, samedi 10 octobre, sur X, le directeur général de Microsoft, Satya Nadella, tout en la jugeant insuffisante. Et de proposer, comme Nvidia, une série de mesures de sécurité incluant des contrôles extérieurs des actions conduites par les différents modèles. Ces débats sur le risque de perdre la lisibilité des raisonnements des IA illustrent les nouvelles responsabilités des entreprises du secteur, qui ne pourront pas faire accepter leur technologie si celle-ci n'est pas fiable.

Alexandre Piquard (Journaliste au service Economie)

Commenter
Réutiliser ce contenu

Édition du jour
Daté du vendredi 30 octobre
Lire le journal numérique
Lire les éditions précédentes

Cours du soir
Affinez vos connaissances avec Françoise Barbe-Gall, historienne de l'art.
Découvrir

Le Monde en partenariat avec Magnum Photos
Tous les tirages
MAGNUM PHOTOS
Jusqu'au 1er novembre, profitez de -15 % sur la vente de tirages signés, avec le code LEMONDE.
Martin Parr
Miyazaki, Japan, 1996.
Abbas
Udaipur, Rajasthan, India.

SERVICES LE MONDE
- Unes du Monde
- Les ateliers du Monde
- Culture générale
- Mots croisés
- Sudokus
- Résultats des élections municipales 2026
- Education
- Gastronomie
- Réutiliser nos contenus
- Consulter les annonces légales
- Le carnet du Monde

GUIDES D'ACHAT LE MONDE
- Les meilleurs robots pâtissiers
- Les meilleurs robots aspirateurs laveurs
- Jeux de société pour adultes
- Le meilleur antivol pour vélo
- Les meilleures friteuses sans huile
- Les meilleures imprimantes laser

LE MONDE À L'INTERNATIONAL
- Le Monde in English
- Algérie
- Belgique
- Canada
- Côte d'Ivoire
- Mali
- Maroc
- Sénégal
- Suisse
- Tunisie

SERVICES PARTENAIRES
- Nos partenaires
- Hits du moment
- Codes promo
- Bons plans et réductions
- Le Monde pour les hôtels
- Apprendre une langue

SITES DU GROUPE
- Le Monde Evènements
- Courrier International
- Télérama
- La Vie
- Le HuffPost
- Le Nouvel Obs
- Le Monde diplomatique
- La société des lecteurs du Monde
- Talents
- Source Sûre
- Le Club de l'économie
- M Publicité

NEWSLETTERS DU MONDE
Recevoir les newsletters du Monde

APPLICATIONS MOBILES
Sur iPhone | Sur Android

ABONNEMENT
Archives du Monde
S'abonner / Se désabonner
Se connecter
Consulter le Journal du jour
Évenements abonnés
Jeux-concours abonnés
Contacter Le Monde

INFORMATIONS LÉGALES LE MONDE
- Mentions légales
- Charte du Groupe
- Politique de confidentialité
- Gestion des cookies
- Conditions générales
- Aide (FAQ)
- Votre avis sur le site

SUIVEZ LE MONDE
Facebook
Youtube
Instagram
Snapchat
TikTok
Fils RSS